

Data Science
CC3084



Excelencia que trasciende

DEL VALLE
GRUPO EDUCATIVO

Laboratorio 1 - Series de Tiempo

Daniela Ramírez de León, 23053
José Pablo Donado López, 22684
Cindy Gualim, 21226

GUATEMALA, 26 de julio de 2026

1. Introducción

Este informe analiza el ingreso de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 (Base_Migracion_2009-2026jun.xlsx: 161,036 registros mensuales en formato largo, sin huecos temporales). Los datos combinan tres fuentes con metodologías distintas (2009-2020, 2021-2022 y 2023-2026jun), lo que genera quiebres estructurales relevantes para el análisis. Desde 2023, la variable País pasa a agrupaciones de mercado y la categoría "Viajero" excluye tránsito fronterizo frecuente, por lo que las comparaciones históricas consistentes se apoyan en Turista + Excursionista. Los datos son de uso exclusivamente académico y no son cifras oficiales del INGUAT ni del IGM.

2. Análisis exploratorio de datos

Estructura: 161,036 filas, 13 columnas (12 meses, 3 vías, 22 fronteras, 235 países/agrupaciones, 17 regiones, 4 tipos de viajero). No hay valores nulos. No hay filas duplicadas; se identificaron 22 combinaciones de llave (año-mes-vía-frontera-país-tipo) repetidas por columnas de clasificación adicionales (42 filas de 2020-2022), sin doble conteo real.

Calidad de categorías: region_dos incluye "0" en 13 registros de 2022 (821 viajeros sin mapear, se trata como "Otros/Sin clasificar"); existen dos etiquetas de cruceros ("Crucevistas"/"Cruceiros"); País cambia de granularidad desde 2023.

Valores atípicos: viajeros está muy sesgada a la derecha (media 324.7, mediana 7, máximo 92,336); ~16% de filas superan el límite IQR, pero son la cola esperada de una variable de conteo muy desagregada, no errores. Un tercio de los valores son decimales (estimaciones de encuesta).




Figura 1. Total mensual de viajeros, 2009-2026 (banda: pandemia).

Comportamiento temporal: tendencia creciente 2009-2019 (2.0 a 4.7 millones anuales), colapso de hasta -97% interanual en 2020 (piso ~73% por debajo de 2019 en 2020-2021), recuperación plena en 2022, y una caída aparente desde 2023 que es metodológica, no real.




Figura 2. Top países por viajeros acumulados.




Figura 3. Viajeros por vía de ingreso y top fronteras.

Países y regiones: El Salvador y Guatemala (residentes) encabezan el ranking, seguidos de EE. UU., Honduras y México. América del Centro concentra 73% del total, América del Norte 18% y Europa 4%.

Vías y fronteras: vía Terrestre 60%, Aérea 36%, Marítima 2%. La Aurora es la frontera individual más usada, pero el conjunto de pasos terrestres con El Salvador (Valle Nuevo, San Cristóbal, Pedro de Alvarado) supera en conjunto al tráfico aéreo.

Tipo de viajero: Turista predomina en todo el período; Viajero cae desde 2023 por cambio metodológico y Cruceistas desaparece del dataset ese mismo año. Turista + Excursionista es la métrica comparable en todo el rango.

3. División entrenamiento / prueba

Se aplicó un corte cronológico 70/30 (no aleatorio). Se decidió conservar los años 2020-2021 dentro de la serie, en lugar de excluirlos, para no romper la equiespaciación mensual y para poder cumplir con el objetivo del laboratorio de analizar el comportamiento durante y después de la pandemia. El efecto de la pandemia se trata como una intervención (variable dummy exógena, marzo 2020 - diciembre 2021) en la serie Total.

Conjunto	Período	Meses	%
Entrenamiento	ene-2009 – mar-2021	147	70%
Prueba	abr-2021 – jun-2026	63	30%




Figura 4. División entrenamiento/prueba sobre la serie total.

4. Construcción de las series de tiempo

A partir del entrenamiento se construyeron 7 series mensuales: el Total obligatorio, y dos categorías con clasificación estable en todo el período: Vías de ingreso (Aérea, Terrestre, Marítima) y Regiones geográficas — las 3 de mayor acumulado en Región dos (América del Centro, América del Norte, Europa). Se descartaron País (cambia de granularidad en 2023) y Tipo de viajero (Viajero cambia de definición y Crucevistas desaparece en 2023).

Serie	Inicio	Fin	N	Media	CV
Total	2009-01	2021-03	147	237,121	0.430
Vía Aérea	2009-01	2021-03	147	89,141	0.330
Vía Terrestre	2009-01	2021-03	147	139,988	0.517
Vía Marítima	2009-01	2020-03	135	8,702	0.781
Región América Del Centro	2009-01	2021-03	147	171,622	0.476
Región América Del Norte	2009-01	2021-03	147	39,235	0.361
Región Europa	2009-01	2021-03	147	9,877	0.392

Nota — Vía Marítima: esta serie cambia de composición tres veces (Crucevistas+Turista hasta 2016, solo Crucevistas 2017-2019, vacío de 19 meses en la pandemia, y solo categoría Viajero desde 2023), por lo que termina en 2020-03 y sus resultados de modelado deben leerse como ilustrativos, no como pronóstico real de tráfico marítimo.

5. Análisis de cada serie

Para cada serie se evaluó: descomposición STL (fuerza de tendencia y estacionalidad), estacionariedad en varianza (razón de varianzas y lambda de Box-Cox) y en media (ADF/KPSS, orden de diferenciación d y D), selección de p, d, q contrastando auto_arima contra el análisis de ACF/PACF, un conjunto fijo de 5 modelos SARIMA candidatos, y los modelos alternativos Holt-Winters (aditivo/multiplicativo), suavizamiento exponencial simple (SES) y seasonal naive. Prophet no pudo evaluarse por no estar disponible en el entorno de cómputo.

5.1 Total (serie obligatoria)

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.394, tendencia 0.789. **Box-Cox λ :** 0.886 (no requiere transformación). **Estacionariedad:** no estacionaria en niveles (ADF $p=0.2998$); estacionaria con $d=1$ ($p=0.0196$); se agrega $D=1$, $s=12$.

Parámetros: auto_arima sugiere SARIMA(2,1,0)(0,1,1)₁₂ (AIC=3272.0); se evaluaron 5 especificaciones alrededor de ese orden.



Figura 5. Total mensual de viajeros, con ventana de pandemia.

Modelo	RMSE	MAPE %
Holt-Winters (mul) — mejor sin intervención	168,288.8	48.8
SARIMA(0,1,1)(0,1,1) ₁₂ — mejor SARIMA sin intervención	421,200.7	137.9
SARIMA(1,1,2)(0,1,1) ₁₂ + COVID — mejor modelo final	75,299.6	28.0



Figura 6. Predicción con modelos SARIMAX que incluyen intervención COVID.

Resultado: incorporar una variable dummy de pandemia (SARIMAX) redujo el RMSE en ~82% frente al mejor SARIMA sin intervención, y superó también a Holt-Winters. Modelo elegido: SARIMA(1,1,2)(0,1,1)₁₂+COVID (RMSE=75,299.6; MAE=60,673.8; MAPE=28.0%).

5.2 Vía Aérea

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.575, tendencia 0.791. **Box-Cox λ :** 1.258 (se recomienda transformar). **Estacionariedad:** no estacionaria en niveles (ADF $p=0.1522$); estacionaria con $d=1$ ($p=0.0011$); $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(0,1,0)(0,1,1)₁₂ (AIC=2914.5); mejor SARIMA evaluado: SARIMA(1,1,2)(0,1,1)₁₂ (AIC=2600.4).



Figura 7. Vía Aérea — predicción sobre el conjunto de prueba.

Resultado: mejor modelo: Holt-Winters multiplicativo (RMSE=29,846.3; MAPE=24.3%, el menor error porcentual de las 7 series), gracias a un patrón estacional muy marcado.

5.3 Vía Terrestre

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.126, tendencia 0.684. **Box-Cox λ :** 0.646 (transformación moderada sugerida). **Estacionariedad:** no estacionaria en niveles (ADF $p=0.3451$); estacionaria con $d=1$ ($p=0.0155$); $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(3,1,0)(0,1,1)₁₂ (AIC=3199.7); mejor SARIMA evaluado: SARIMA(1,1,2)(0,1,1)₁₂ (AIC=2853.0).




Figura 8. Vía Terrestre — predicción sobre el conjunto de prueba.

Resultado: mejor modelo: Holt-Winters multiplicativo (RMSE=135,351.2; MAPE=60.9%); ningún modelo sin intervención reproduce bien la recuperación pos-pandemia.

5.4 Vía Marítima

Período: 2009-01 – 2020-03 (N=135). **STL:** estacionalidad 0.712 (máxima), tendencia 0.195 (mínima). **Box-Cox λ :** 0.426 (se recomienda transformar). **Estacionariedad:** no estacionaria en niveles (ADF $p=0.4490$); estacionaria con $d=1$ ($p=0.0004$); $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(1,0,1)(0,1,2)₁₂ (AIC=2413.4); mejor SARIMA evaluado: SARIMA(1,1,2)(0,1,1)₁₂.




Resultado: mejor modelo: suavizamiento exponencial simple (RMSE=8,024.1). El MAPE es extremo ($>1,000\%$) en todos los modelos por valores reales cercanos a 0 en la prueba; resultado ilustrativo, no operativo (ver nota sección 4).

5.5 Región América del Centro

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.221, tendencia 0.747. **Box-Cox λ :** 0.709 (transformación ligera sugerida). **Estacionariedad:** no estacionaria en niveles (ADF $p=0.3540$); estacionaria con $d=1$ ($p=0.0124$); $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(2,1,0)(0,1,1)₁₂ (AIC=3221.1); mejor SARIMA evaluado: SARIMA(1,1,2)(0,1,1)₁₂ (AIC=2872.0).



Resultado: mejor modelo: Holt-Winters multiplicativo (RMSE=124,018.4; MAPE=47.0%); subestima la velocidad de la recuperación pos-pandemia.

5.6 Región América del Norte

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.469, tendencia 0.595. **Box-Cox λ :** 0.916 (no requiere transformación). **Estacionariedad:** ADF en niveles rechaza raíz unitaria ($p=0.0191$), pero se aplicó $d=1$ por la estacionalidad marcada; $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(2,1,2)(0,1,1)₁₂ (AIC=2765.1); mejor SARIMA evaluado: SARIMA(1,1,2)(0,1,1)₁₂ (AIC=2455.7).




Figura 11. Región América del Norte — predicción sobre el conjunto de prueba.

Resultado: mejor modelo: Holt-Winters multiplicativo (RMSE=28,259.8; MAPE=41.5%). Es la región con mayor caída máxima por la pandemia (100%).

5.7 Región Europa

Período: 2009-01 – 2021-03 (N=147). **STL:** estacionalidad 0.600, tendencia 0.713. **Box-Cox λ :** 0.944 (no requiere transformación). **Estacionariedad:** no estacionaria en niveles ni con $d=1$ ($p=0.5049$); estacionaria con $d=2$ (única serie con $d=2$); $D=1$, $s=12$.

Parámetros: auto_arima: SARIMA(2,1,0)(0,1,1)₁₂ (AIC=2384.4); mejor SARIMA evaluado: SARIMA(2,1,2)(1,1,1)₁₂ (AIC=2114.9).




Figura 12. Región Europa — predicción sobre el conjunto de prueba.

Resultado: mejor modelo: Holt-Winters multiplicativo (RMSE=10,167.2; MAPE=67.5%); también entre las regiones con caída máxima de 100% por la pandemia.

6. Análisis comparativo

Serie	Estacionalidad	Tendencia	Crecim. anual %	CV	Caída COVID %
Total	0.394	0.789	4.02	0.430	97.5
Vía Aérea	0.575	0.791	0.97	0.330	99.6
Vía Terrestre	0.126	0.684	6.15	0.517	97.8
Vía Marítima	0.712	0.195	5.62	0.781	39.9
Región América Del Centro	0.221	0.747	5.47	0.476	96.8
Región América Del Norte	0.469	0.595	-0.25	0.361	100.0
Región Europa	0.600	0.713	-0.70	0.392	100.0

- **Mayor estacionalidad:** Vía Marítima (0.712), por su fuerte dependencia del calendario de cruceros.
- **Mayor tendencia de crecimiento:** Vía Terrestre (6.15% anual).
- **Mayor volatilidad:** Vía Marítima (CV=0.781).
- **Más afectada por la pandemia:** Región América del Norte (100% de caída máxima, empatada con Europa); el turismo de larga distancia se detuvo por completo, mientras el flujo terrestre centroamericano nunca llegó a cero.

Desempeño predictivo: la vía aérea tuvo el menor error porcentual (MAPE=24.3%) por su estacionalidad regular; la vía marítima el mayor (MAPE>1,000%) por el cambio de composición de sus registros. En las 6 series sin variable de intervención, Holt-Winters multiplicativo fue sistemáticamente el mejor modelo (excepto SES en Marítima); incorporar una variable dummy de COVID —como se hizo para el Total, con una mejora de ~82% en RMSE— es la extensión natural pendiente para las 6 series restantes.

Hallazgos para el INGUAT

- El 73% de los viajeros proviene de Centroamérica y el 60% ingresa por vía terrestre: priorizar promoción e infraestructura fronteriza terrestre.
- Estacionalidad estable (máximos jul-ago y dic-ene): permite planificar personal y campañas con anticipación.
- La pandemia generó un quiebre que los modelos sin intervención no logran capturar: usar SARIMAX/ARIMAX con variables de intervención en los pronósticos institucionales.
- Los cambios metodológicos de 2023 (País, Tipo de Viajero) limitan la comparación histórica: usar indicadores agregados comparables (Turista+Excursionista) y documentar los cambios.
- Alta concentración en pocos puntos de ingreso (La Aurora y fronteras con El Salvador): fortalecer infraestructura y contingencia, y diversificar accesos.

7. Conclusiones

- El dataset es de buena calidad: sin nulos ni duplicados reales; las inconsistencias menores detectadas fueron documentadas y tratadas.
- Las 7 series comparten tendencia creciente 2009-2019 y un quiebre severo por la pandemia; ninguna es estacionaria en niveles (todas requieren $d=1$ y $D=1$, salvo Europa con $d=2$).
- Holt-Winters multiplicativo fue el mejor modelo base en 6 de 7 series; SES en Vía Marítima. Prophet no pudo evaluarse por no estar disponible en el entorno.
- Incorporar una variable de intervención COVID mejora drásticamente la predicción (RMSE -82% en la serie Total) y se recomienda extenderla a las demás series.
- Vía Marítima debe interpretarse con cautela: cambia de composición tres veces en el período de estudio.
- Hallazgo más accionable para el INGUAT: la concentración del turismo en el corredor terrestre centroamericano y en el Aeropuerto La Aurora, que sugiere priorizar inversión en esos puntos.